

Web Trafik Loglarına Dayalı Yapay Zeka Destekli Soru-Cevap Sistemi Geliştirme

**Hazırlayan:
Mehmet Ok**

Proje GitHub:

[https://github.com/Mehmet-Ok/
ArtificialIntelligenceSupportedQuestionandAnswerSystemBasedonWebTrafficLogs](https://github.com/Mehmet-Ok/ArtificialIntelligenceSupportedQuestionandAnswerSystemBasedonWebTrafficLogs)

Veri Seti İçeriği:

- IP Adresleri: Kullanıcıların web sunucusuna bağlanırken kullandıkları IP adresleri.
- Zaman Damgaları: Her bir isteğin (request) sunucuya ulaştığı tarih ve saat bilgisi.
- HTTP Metotları: GET, POST gibi isteklerin türünü belirten HTTP metotları.
- İstenen Kaynaklar: Kullanıcıların web sitesinde hangi sayfaları veya dosyaları (örneğin, görseller, JavaScript dosyaları) talep ettiğini gösterir.
- HTTP Durum Kodları: İsteğin başarılı olup olmadığını (200), yönlendirildiğini (301), hata verdiğini (404) belirten kodlar.
- Tarayıcı Bilgileri: Kullanıcıların kullandığı tarayıcı ve işletim sistemi hakkında bilgiler.

Veri Seti Formatı:

Veri seti .log metin dosyası formatındadır. Her satır bir isteği temsil eder ve bilgiler boşluklar veya sekmeler ile ayrılmıştır.

Projede izlenen yolun genel hatları ile özeti:

1. Verinin işlenmesi ve temizlenmesi
 1. log kayıtlarının ayrıştırılarak dataframe yapısında depolanması
 2. HTTP metodu, istek durumu, referer bilgisi, istek yapılan cihaz hakkında bilgiler, istek yapılan dosya/adresin ismi gibi bilgilerin çıkarılması
 3. Çıkarılan bilgilerin arasından eksik, bozuk olanların silinmesi
 4. İstek URL'lerinin arasından query içerenlerin ayrıştırılması
2. Temizlenmiş haldeki verinin
 1. Doğal dil yapısındaki cümlelere dönüşümü
 2. Cümlelerin sentence-BERT modeli ile vektörlere dönüşümü
3. Cümle vektörlerinin Faiss Vector Database'de depo edilmesi
4. Bilgi alma fonksiyonunun kurulması
5. Jeneratif modelin seçilmesi ve veri hazırlığı
 1. T5-small modeli seçildi
 2. Temizlenip dataframe yapısına aktarılan veriden Q&A çiftleri otomatik şekilde oluşturulması
6. Jeneratif modelin oluşturulan Q&A çiftleri ile eğitilmesi
7. RAG yapısının bilgi alma fonksiyonu ve jeneratif model kullanılarak eğitilmesi

Karşılaşılan zorluklar:

- log kayıtlarındaki query içeren istekleri doğal dile oturtmanın bir yolunu bulamadım. Bu sorun log kayıtlarının yapısı hakkındaki yetersizliğimden kaynaklanıyor diye düşünüyorum. Burda çok basit bir çözüm olan query içeren log kayıtlarını filtreleyerek işleme devam etme yolunu seçtim. Ayrıca src klasörü içinde bulunan createSentenceLogAndSamps.ipynb dosyasında yorum satırı halinde bu işlemin python kodlarını bıraktım.

- Projeyi yaparken en çok zorlandığım kısım RAG yapısını öncelikle kafamda sonra ise kod üzerinde oturtabilmek oldu. Bu konuda karşılaştığım zorlukları madde madde belirteceğim:
 - Model çıkış boyutu ve faiss index boyutunun uyuşmaması. Bu sorun RAG modelinin ilk başta çalışmaz halled bulmama neden oldu. Bunun çözümü için **DimensionReducer** sınıfını yazdım. Bu sınıf bir PyTorch modülüdür. PyTorch kullanarak boyut indirgeme yapabilen bir sinir ağıdır. Model içinde forward propagation işlemi yapılmaktadır. encode_query fonksiyonu içerisinde kullanılmıştır.
 - İlk denemelerimde RAG modeli içinde jeneratif modelin inputunun vektörleşmiş queryler olduğunu düşünerek yazdım belirli bir süre bu düşünce ile ilerledim fakat RAG yapısı hakkında yeterli bilgim olmadığı için daha fazla araştırmaya karar verdim. Bu araştırma sonucunda yanlış ilerlediğimi fark edip RAG yapısını olması gerektiği şekilde faiss vektör veri tabanı üzerinde queryleri çalıştırıp jeneratif modele yönlendirecek şekilde tekrar tasarladım.
- Q&A çiftlerini ilk oluşturduğumda yine her şey doğru gidiyor diye düşündüm. Çiftleri oluşturup bunlarla jeneratif modeli eğittim fakat eğitimden sonra çiftlerin cevaplarında farklı sorular için aynı cevaplar yazdığımı fark ettim. Bunu çözmek için çiftleri oluşturan fonksiyona geri dönerek üretilen bütün cevaplar unique olacak şekilde bazı düzenlemeler yaptım. Modeli baştan eğiterek sorunu çözdüm.

SONUÇLAR

Jeneratif modelin perplexity skoru 4.8'dir.(modelin daha önce görmediği 500 adet Q&A çifti ile test edildi)

RAG modelinin;

ROUGE Scores:

```
{  
  'rouge1': 0.7521844072415915,  
  'rouge2': 0.7011706245285423,  
  'rougeL': 0.7515461350302483,  
  'rougeLsum': 0.7518870822988801  
}
```

BLEU Score:

```
{  
  'bleu': 0.6673614601737361,  
  'precisions':  
  [0.7450620456714884,0.6776431130421526,0.639432601632459,0.614407129301097],  
  'brevity_penalty': 1.0,  
  'length_ratio': 1.1901599230970898,  
  'translation_length': 13619,  
  'reference_length': 11443  
}
```

RAG modeli 500 adet Q&A çifti ile test edilmiştir.

```
[8] 1 query = "What was the status of the request from IP address 66.249.66.91 to /css/font/wyekan/font.woff on 2019-01-25 00:38:49?"  
    2 answer = retrieve_and_generate(query)  
    3 print("Answer:", answer)
```

 Answer: The status of the request from IP address 66.249.66.91 to /css/font/wyekan/font.woff on 2019-01-25 00:38:49 was success.